

Sprawozdanie - Projekt 3: Podstawy Gymnasium, zadanie na 4 punkty

Algorytm: Q-Learning z eksploracją ϵ -greedy

Środowisko: FrozenLake-v1

1. Opis środowiska

Środowisko **FrozenLake-v1** z pakietu `gymnasium` symuluje poruszanie się po zamrożonym jeziorze o siatce 4×4 . Agent startuje z pola S i stara się dotrzeć do pola G (cel) bez wpadnięcia w dziury H. Przestrzeń stanów jest dyskretna i liczy 16 stanów, a przestrzeń akcji zawiera 4 ruchy: LEFT (0), DOWN (1), RIGHT (2), UP (3).

```
S F F F
F H F H
F F F H
H F F G
```

Symbol	Znaczenie
S	Start (stan 0)
F	Frozen - bezpieczne pole lodowe
H	Hole - dziura, epizod kończy się porażką (nagroda = 0)
G	Goal - cel, epizod kończy się sukcesem (nagroda = 1)

Kluczową cechą zastosowanej konfiguracji jest parametr `is_slippery=True`, który wprowadza stochastyczność środowiska: gdy agent wybiera daną akcję, z prawdopodobieństwem $1/3$ wykonuje ją zgodnie z zamierzeniem, a z prawdopodobieństwem $2/3$ przesuwa się prostopadle (po $1/3$ na każdą stronę). Oznacza to, że środowisko jest **niedeterministyczne** - ten sam stan i akcja mogą prowadzić do różnych stanów następnych. Jest to realistyczna i trudniejsza wersja problemu, w odróżnieniu od wersji deterministycznej (`is_slippery=False`).

2. Algorytm Q-Learning

2.1 Podstawy teoretyczne

Zastosowano algorytm **Q-Learning** - klasyczny algorytm uczenia ze wzmocnieniem z kategorii metod off-policy. Algorytm uczy się funkcji wartości akcji $Q(s, a)$, która reprezentuje oczekiwaną zdyskontowaną nagrodę sumaryczną, jaką agent może osiągnąć, rozpoczynając ze stanu s , wykonując akcję a , a następnie postępując zgodnie z optymalną polityką.

Aktualizacja tablicy Q odbywa się zgodnie z **równaniem Bellmana**:

$$Q(s, a) \leftarrow Q(s, a) + \alpha \left[r + \gamma \max_{a'} Q(s', a') - Q(s, a) \right]$$

gdzie:

- $Q(s, a)$ - bieżąca wartość stanu-akcji
- α - współczynnik uczenia (learning rate)
- r - natychmiastowa nagroda otrzymana po wykonaniu akcji a w stanie s
- γ - **współczynnik dyskontowy** (ustawiony na **0.9**)
- s' - stan następny po wykonaniu akcji
- $\max_{a'} Q(s', a')$ - maksymalna wartość Q dla stanu następnego (bootstrapping)

Wyrażenie w nawiasach $[r + \gamma \max_{a'} Q(s', a') - Q(s, a)]$ nosi nazwę **błędu TD** (temporal difference error) - mierzy różnicę między aktualnym oszacowaniem a lepszym oszacowaniem wynikającym z otrzymanej nagrody i przyszłych wartości.

Współczynnik dyskontowy $\gamma = 0.9$ oznacza, że agent ceni przyszłe nagrody, ale nieco mniej niż nagrody bezpośrednie. Nagroda oddalona o k kroków jest ważona współczynnikiem 0.9^k , co zachęca agenta do znajdowania krótszych ścieżek do celu.

2.2 Strategia eksploracji: ϵ -greedy

Aby równoważyć eksplorację nowych ścieżek z eksploatacją nabytej wiedzy, zastosowano politykę **ϵ -greedy**:

- z prawdopodobieństwem ϵ agent wybiera losową akcję (**eksploracja**)
- z prawdopodobieństwem $(1 - \epsilon)$ agent wybiera akcję z najwyższą wartością Q (**eksploatacja**)

Wartość ϵ maleje wykładniczo w trakcie treningu:

$$\epsilon_{t+1} = \max(\epsilon_{\min}, \epsilon_t \cdot d)$$

gdzie $d = 0.9995$ to współczynnik zaniku. Dzięki temu agent stopniowo przechodzi od pełnej eksploracji ($\epsilon = 1.0$) do niemal czystej eksploatacji ($\epsilon \rightarrow 0.01$).

3. Implementacja

3.1 Środowisko i tablica Q

Środowisko tworzone jest z użyciem `gymnasium.make("FrozenLake-v1", map_name="4x4", is_slippery=True)`. Tablica Q inicjalizowana jest zerami o wymiarach (16 stanów $\times$ 4 akcje). Zerowa inicjalizacja jest neutralna i właściwa dla środowisk z nagrodami nieujemnymi.

3.2 Pętla treningowa

W każdym epizodzie:

1. Środowisko jest resetowane do stanu S (z unikalnym seedem dla reprodukowalności)
2. W każdym kroku agent wybiera akcję zgodnie z polityką ϵ -greedy
3. Środowisko zwraca stan następny s' , nagrodę r i flagę zakończenia
4. Tablica Q jest aktualizowana regułą Bellmana
5. Przy zakończeniu epizodu (wpadnięcie w dziurę lub osiągnięcie celu) pętla kroków zostaje przerwana
6. Wartość ϵ jest redukowana

Trening obejmuje **10 000 epizodów** z maksymalnie 100 krokami na epizod.


3.3 Hiperparametry

Parametr	Wartość	Opis
Epizody	10 000	Łączna liczba epizodów treningowych
Max kroków	100	Maksymalna długość epizodu
α (learning rate)	0.8	Szybkość aktualizacji tablicy Q
γ (discount)	0.9	Współczynnik dyskontowy
ϵ startowe	1.0	Pełna eksploracja na początku
ϵ minimalne	0.01	Dolna granica eksploracji
ϵ decay	0.9995	Wykładnicze zanikanie ϵ na epizod

4. Eksperymenty i wyniki

4.1 Krzywa uczenia

Poniżej przedstawiono krzywą uczenia (wygładzona średnia krocząca z oknem 100 epizodów), długość epizodów oraz zanikanie ϵ w trakcie treningu.



Wykres pokazuje trzy wyraźne fazy uczenia:

- 1. Faza eksploracji (ep. 1-3000):** Wskaźnik sukcesu jest niski (1-6%). Agent eksploruje środowisko niemal losowo - wartości Q są dopiero budowane, a ϵ jest wysokie (0.74 po 3000 ep.).
- 2. Faza przejściowa (ep. 3000-7000):** Widoczny wyraźny wzrost skuteczności (od $\sim 10\%$ do $\sim 29\%$). Agent zaczyna eksploatować nabytą wiedzę. ϵ spada do poziomu ~ 0.22 .
- 3. Faza eksploatacji (ep. 7000-10000):** Wskaźnik sukcesu rośnie szybciej, osiągając $\sim 48\%$ przy $\epsilon \approx 0.01$. Polityka jest coraz bardziej deterministyczna.

4.2 Wskaźnik sukcesu w trakcie treningu

Epizody	Średni wskaźnik sukcesu
1-1000	1.8%
1001-2000	4.0%
2001-3000	5.8%
3001-4000	10.5%
4001-5000	15.1%
5001-6000	19.5%
6001-7000	29.3%
7001-8000	36.3%
8001-9000	40.2%
9001-10000	48.3%

Wskaźnik sukcesu w trakcie treningu jest zaniżony w stosunku do rzeczywistych możliwości polityki, gdyż uwzględnia epizody z wysokim ϵ (agent działał częściowo losowo). Jest to normalny efekt dla algorytmu off-policy.

4.3 Ewaluacja wyuczonej polityki


Po treningu przeprowadzono ewaluację na **1000 epizodach** z czystą polityką zachłanną ($\epsilon = 0$):

Wskaźnik sukcesu: 75.0%

Wynik 75% jest zgodny z wartościami typowymi dla Q-Learning na FrozenLake-v1 (śliskie podłoże). Środowisko to ma ograniczoną maksymalną osiągalną skuteczność ze względu na stochastyczność przejść - nawet optymalna polityka nie może zagwarantować 100% sukcesu, gdyż agent może być „zepchnięty” w dziurę mimo prawidłowych decyzji.

4.4 Wyuczona polityka

Tablica Q po treningu daje następującą politykę (najlepsza akcja w każdym stanie):



Polityka jest intuicyjnie poprawna: agent ogólnie kieruje się w stronę celu (G w prawym dolnym rogu), omijając dziury (H). Na polach przy dziurach widoczna jest tendencja do wybierania bezpiecznych obejść.

5. Analiza i wnioski

Poprawność implementacji: Algorytm Q-Learning z regułą Bellmana i eksploracją ϵ -greedy jest zaimplementowany zgodnie ze specyfikacją teoretyczną. Wartości tablicy Q po treningu rosną w kierunku celu, co potwierdza prawidłowe propagowanie nagród.

Wpływ stochastyczności środowiska: Parametr `is_slippery=True` znacząco utrudnia uczenie. W wersji deterministycznej (`is_slippery=False`) wskaźnik sukcesu osiąga $\sim 95\text{-}100\%$ po stosunkowo niewielkiej liczbie epizodów. W wersji stochastycznej:

- Agent potrzebuje więcej epizodów do stabilnego uczenia
- Wartości Q są niższe i „rozmyte” (uśredniają stochastyczne przejścia)
- Maksymalny osiągalny wskaźnik sukcesu jest ograniczony fizycznie

Rola współczynnika $\gamma = 0.9$: Wartość $\gamma = 0.9$ jest odpowiednim kompromisem dla tego środowiska. Wyższe γ (np. 0.99) skłoniłoby agenta do dokładniejszego planowania długoterminowego, ale mogłoby spowolnić konwergencję. Niższe γ (np. 0.5) spowodowałoby, że agent przedkładałby krótkoterminowe „przeżycie” nad dotarcie do celu.

Zbieżność: Algorytm wykazuje monotonicznie rosnący wskaźnik sukcesu, co świadczy o prawidłowej zbieżności Q-Learningu. Metoda gwarantuje zbieżność do optymalnej polityki przy odpowiednio małym α i pełnej eksploracji.