

Sprawozdanie - Projekt 4: Własne środowisko Gymnasium

Rolling Ball Navigator

Autorzy: Patrick Bajorski, Jan Banasik **Data:** 06.05.2026

1. Środowisko

1.1 Opis problemu

Zaimplementowano środowisko **Rolling Ball Navigator** - kulka poruszająca się po prostokątnej planszy musi dotrzeć do losowo wyznaczonego celu, omijając po drodze statyczne przeszkody prostokątne. Środowisko zostało zaimplementowane zgodnie ze standardowym interfejsem Gymnasium (metody `reset`, `step`, `render`, `close`), z ciągłą przestrzenią obserwacji i akcji.

Plansza ma wymiary 600×600 pikseli i zawiera 6 statycznych przeszkód prostokątnych tworzących nietrywialny układ wymagający aktywnego omijania. Na początku każdego epizodu pozycja startowa kulki oraz pozycja celu są losowane niezależnie w obszarach wolnych od przeszkód, w odległości co najmniej 100 pikseli od siebie.

1.2 Fizyka ruchu

W każdym kroku czasowym prędkość kulki jest aktualizowana zgodnie z uproszczoną fizyką newtonowską (w kodzie dodatkowo stosowane jest twarde ograniczenie prędkości do $\pm V_MAX$ po dodaniu przyspieszenia):

```
vel = clip(vel + action * FORCE_SCALE, -V_MAX, V_MAX) # (FORCE_SCALE =  
vel *= FRICTION                                     # (FRICTION = 0.92, tłumienie prędkości)  
pos += vel
```

Przy zderzeniu ze ścianą planszy lub przeszkodą prostokątną odpowiednia składowa prędkości zmienia znak (sprężyste odbicie), a pozycja kulki jest korygowana o wartość nakładania. Stałe `BALL_RADIUS = 12` i `GOAL_RADIUS = 18` definiują rozmiary obiektów.

1.3 Przestrzeń obserwacji

Obserwacja jest ciągłym wektorem 13 liczb zmiennoprzecinkowych (`spaces.Box`, `dtype=float32`). Wszystkie wartości są znormalizowane do zakresu $[-1, 1]$ lub $[0, 1]$:

Indeks	Opis	Zakres
0-1	Prędkość kulki (x, y) / <code>v_MAX</code>	$[-1, 1]$
2-3	Znormalizowany kierunek do celu (x, y)	$[-1, 1]$
4	Odległość do celu / przekątna planszy	$[0, 1]$
5-12	8 sensorów odległości (raycasting, co 45°) / <code>RAY_MAX</code>	$[0, 1]$

Agent nie zna swojej pozycji absolutnej na planszy - nawiguje wyłącznie na podstawie lokalnych informacji. Sensory odległości (raycasting metodą słab AABB) wykrywają zarówno ściany planszy, jak i przeszkody prostokątne, dając agentowi możliwość „wyczucia” otoczenia bez dostępu do mapy.

1.4 Przestrzeń akcji

Akcja jest ciągłym wektorem dwuwymiarowym (`spaces.Box`, $[-1, 1]^2$), reprezentującym siłę przykładaną do kulki w osiach X i Y. Brak dyskretyzacji kierunków daje agentowi pełną swobodę sterowania.

1.5 Funkcja nagrody

Zastosowana funkcja nagrody łączy kształtowanie gęste z nagrodą końcową:

```
nagroda = -0.01 + 0.02 * (poprzednia_dist - aktualna_dist)
jeśli cel osiągnięty: nagroda += 50.0
```

Składnik -0.01 na krok motywuje agenta do szybkości. Składnik $0.02 * \Delta \text{dist}$ to gęste kształtowanie nagrody - agent otrzymuje proporcjonalny sygnał za każde zbliżenie się do celu w danym kroku, co eliminuje problem rzadkiej nagrody. Nagroda $+50.0$ za dotarcie do celu stanowi silny sygnał końcowy.

1.6 Warunki zakończenia epizodu


Epizod kończy się sukcesem (`terminated=True`), gdy środek kulki znajdzie się w promieniu `GOAL_RADIUS + BALL_RADIUS` od celu. Przekroczenie limitu `MAX_STEPS = 500` kroków kończy epizod przez timeout (`truncated=True`).

1.7 Tryb graficzny

Środowisko implementuje metodę `render()` obsługującą dwa tryby:

- "human" - interaktywne okno pygame do obserwacji działania agenta w czasie rzeczywistym
- "rgb_array" - zwracana macierz pikseli, wykorzystana w notebooku do zapisu nagrania epizodów (plik episode.mp4)

W trybie graficznym renderowane są: plansza (tekstura kafelkowa), przeszkody, sprite kulki (sprites/agent.png), sprite celu (sprites/goal.png) oraz jasne linie (złotawy kolor) reprezentujące promienie sensorów odległości.



2. Algorytm uczenia

2.1 Wybór algorytmu

Do treningu agenta zastosowano algorytm **SAC (Soft Actor-Critic)** z biblioteki `stable-baselines3`. SAC jest algorytmem off-policy opartym na maksymalizacji entropii - optymalizuje zarówno oczekiwaną nagrodę, jak i entropię polityki, co sprzyja eksploracji i zapobiega przedwczesnemu

zbieganiu do lokalnych minimów. Jest to algorytm szczególnie dobrze dopasowany do ciągłych przestrzeni akcji, w których metody on-policy jak PPO wymagają znacznie większej liczby próbek.

2.2 Hiperparametry

Parametr	Wartość	Uzasadnienie
learning_rate	3e-4	Standardowa wartość dla SAC z sieciami MLP
buffer_size	300 000	Replay buffer pokrywający >50% całego treningu
learning_starts	5 000	Zbieranie danych losowych przed pierwszą aktualizacją
batch_size	256	Dobry balans między wariancją gradientu a szybkością
gamma	0.99	Duże znaczenie przyszłych nagród - cel może być wiele kroków od startu
ent_coef	0.1 (stały)	Ustalony ręcznie - patrz sekcja 3.2
total_timesteps	500 000	~50 minut na GPU (CUDA)

3. Eksperymenty

3.1 Problem rzadkiej nagrody

W pierwszej wersji środowiska nagroda za dotarcie do celu wynosiła +10, kara za krok -0.01, a limit epizodu wynosił 1000 kroków. Łączna kara za timeout ($1000 \times 0.01 = 10.0$) dokładnie równoważyła nagrodę końcową - agent był więc obojętny na dotarcie do celu. Trening przez 500 000 kroków nie przyniósł żadnego postępu ($ep_rew_mean \approx -10$ przez cały czas).

Zastosowane poprawki: podniesienie nagrody za cel do +50, skrócenie epizodów do `MAX_STEPS = 500` oraz wprowadzenie gęstego kształtowania nagrody $0.005 * \Delta dist$.

3.2 Niestabilność treningu - nienormalizowane obserwacje i auto-tuning entropii

Po poprawkach z sekcji 3.1 trening ruszył, jednak zaobserwowano nieprawidłowe zachowanie: `ent_coef` rósł stopniowo z 0.1 do wartości

powyżej 3.0, a `critic_loss` wynosił ~ 249 . Diagnozy ujawniły dwie powiązane przyczyny:

1. **Nienormalizowane obserwacje** - wektory obserwacji zawierały wartości z bardzo różnych zakresów (np. odległość do celu mogła wynosić ~ 848 pikseli, podczas gdy prędkości były rzędu ± 5). Taka dysproporcja powoduje, że gradienty sieci krytyka są zdominowane przez największe wartości, co prowadzi do wysokiego `critic_loss` i niestabilnego uczenia.
2. **Auto-tuning entropii** - domyślny mechanizm SAC automatycznie dostosowuje `ent_coef`, dążąc do docelowej entropii. W warunkach niestabilnego krytyku mechanizm ten nakręcał entropię polityki zamiast ją stabilizować, co prowadziło do coraz bardziej losowego zachowania agenta.

Zastosowane poprawki: pełna normalizacja wszystkich 13 obserwacji do zakresów $[-1, 1]$ lub $[0, 1]$ oraz ustawienie `ent_coef=0.1` jako stałej wartości (wyłączenie auto-tuningu). Po tych zmianach `critic_loss` spadł poniżej 0.01.


3.3 Zamrażanie agenta w pobliżu ścian i przeszkód

W kolejnej iteracji znaczna część epizodów kończyła się timeoutem, bo agent po prostu pozostawał nieruchomy blisko ściany lub przeszkody. Przyczyną było stosowanie kary -0.1 za każde zderzenie. Kumulatywna kara za aktywne poruszanie się i wielokrotne zderzenia (np. przy próbie ominięcia przeszkody) była wyższa niż kara za bezczynność ($-0.01/\text{krok}$). Agent odkrył, że strategia „stój w miejscu” minimalizuje karę.

Zastosowane poprawki: całkowite usunięcie kary za zderzenie - fizyczne odbicie jest wystarczającą konsekwencją. Jednocześnie wzmocniono kształtowanie nagrody z 0.005 do $0.02 * \Delta \text{dist}$, żeby sygnał w kierunku celu był silniejszy od kary za czas.

4. Wyniki

4.1 Krzywa uczenia



Przełom w uczeniu nastąpił stosunkowo wcześnie - już około 65 000 kroków nagroda ewaluacyjna osiągnęła ~ 54 z niską wariancją (± 1.9). Pozostałe $\sim 430\,000$ kroków pozwoliło na dopracowanie polityki i zmniejszenie średniej liczby kroków do celu.

W pierwszych 60 000 krokach widoczne są duże oscylacje nagrody ewaluacyjnej, co jest typowe dla fazy eksploracji SAC - bufor powtórzeń jest jeszcze niepełny, a polityka dopiero się kształtuje.

4.2 Ewaluacja finalnego modelu

Model deterministyczny oceniono na 30 niezależnych epizodach z losowymi pozycjami startowymi:

Metryka	Wartość
Skuteczność (dotarcie do celu)	100.0% (30/30)
Średnia nagroda	54.90 ± 1.56
Średnia liczba kroków	123.3 ± 76.2
Maks. dostępne kroki	500

Agent konsekwentnie osiąga cel w średnio ~ 123 krokach (25% dostępnego limitu), co wskazuje na aktywną strategię nawigacji, a nie przypadkowe poszukiwanie. Niskie odchylenie standardowe nagrody (± 1.56) świadczy o stabilności wyuczonej polityki. Zmienność liczby kroków (± 76.2) wynika z losowości pozycji startowych - epizody z celem odległym o ponad 500 pikseli wymagają dłuższej trajektorii niż te z bliskim celem.

5. Wnioski

Przeprowadzone eksperymenty ilustrują kilka praktycznych kwestii w uczeniu ze wzmocnieniem:

1. **Gęste kształtowanie nagrody jest niezbędne** przy zadaniach, gdzie rzadka nagroda końcowa jest trudna do odkrycia. Sygnał $0.02 * \Delta dist$ w każdym kroku umożliwił szybką konwergencję.
2. **Normalizacja obserwacji ma krytyczne znaczenie** dla stabilności treningu z sieciami neuronowymi. Niezbalansowane skale wejść prowadzą do wysokiego `critic_loss` i niestabilnego auto-tuningu entropii.
3. **Funkcja nagrody może prowadzić do niepożądanych zachowań**
 - kara za zderzenia, choć intuicyjnie sensowna, stworzyła bodziec do całkowitej bezczynności. Poprawna konstrukcja nagrody wymaga analizy strategii, które ona faworyzuje, nie tylko tych, które miała penalizować.
4. **SAC z wyłączonym auto-tuningiem entropii** (`ent_coef=0.1`) okazał się bardziej stabilny w tym środowisku niż wariant z automatyczną regulacją, gdzie mechanizm dostosowywania entropii wchodził w pętlę sprzężenia zwrotnego z niestabilnym krytykiem.